

# Técnicas de optimización

Marcos Esteve Casademunt

Octubre 2018

Demostrar que en cualquier problema de clasificación en  $C$  clases, la estimación de máxima verosimilitud de la probabilidad a priori de la clase  $c$ ,  $1 \leq c \leq C$  es  $p_c = n_c/N$  donde  $N = n_1 + \dots + n_c$  es el número total de datos observados y  $n_c$  es el número de datos de la clase  $c$ .

Modelo:

$$P(c=1) = p_1, \dots, P(c=C) = p_c$$

$$\sum_{c=1}^C p_c = 1$$

$$\theta = (p_1, \dots, p_c)$$

Verosimilitud y logaritmo de la verosimilitud:

$$P(S|\theta) = \prod_{c=1}^C \prod_{i=1}^{n_c} p_c = p_1^{n_1} * \dots * p_c^{n_c}$$

$$q_s(\theta) = L_s(\theta) = \log(P(S|\theta)) = \sum_{c=1}^C n_c \log(p_c)$$

$$\theta^* = \underset{\sum_{c=1}^C p_c=1}{\operatorname{argmax}} \sum_{c=1}^C n_c \log(p_c)$$

Lagrangiana:

$$\Lambda(p_1, \dots, p_c, \beta) = \sum_{c=1}^C n_c \log(p_c) + \beta(1 - \sum_{c=1}^C p_c)$$

Soluciones óptimas en función del multiplicador de Lagrange:

$$\frac{\delta \Lambda}{\delta p_c} = \frac{n_c}{p_c} - \beta = 0$$

$$P_c(\beta) = \frac{n_c}{\beta}$$

Función dual de Lagrange: Aplicaremos propiedades de los logaritmos...

$$\Lambda_D(\beta) = \sum_{c=1}^C n_c \log\left(\frac{n_c}{\beta}\right) + \beta\left(1 - \sum_{c=1}^C \frac{n_c}{\beta}\right)$$

$$= n_1 \log(n_1) - n_1 \log(\beta) + \dots + n_C \log(n_C) - n_C \log(\beta) + \beta - N$$

$$= -N \log(\beta) + \sum_{c=1}^C n_c \log(n_c) + \beta - N$$

Valor óptimo del multiplicador de Lagrange:

$$\frac{\delta \Lambda_D}{\delta \beta} = \frac{-N}{\beta} + 1 = 0 \Rightarrow \beta^* = N$$

Solución final:

$$p_1^* = \frac{n_1}{N} \quad \dots \quad p_c^* = \frac{n_c}{N}$$

Existe una variante de la función de Widrow-Hoff que incluye un término de regularización con el objetivo de que los pesos no se hagan demasiado grandes:

$$q_s(\boldsymbol{\theta}) = \frac{1}{2} \sum_{n=1}^N \left( \boldsymbol{\theta}^t \mathbf{x}_n - y_n \right)^2 + \frac{\boldsymbol{\theta}^t \boldsymbol{\theta}}{2}$$

Aplicando la técnica de descenso por gradiente, obtener la correspondiente variante del algoritmo de Widrow-Hoff y la correspondiente versión muestra a muestra.

$$\nabla q_s(\theta) = \sum_{n=1}^N (\theta^t x_n - y_n) x_n + \theta$$

Suponiendo que:

$$v = (x, y, z) \quad \frac{\delta v^t v}{\delta v} = \frac{\delta(x^2, y^2, z^2)}{\delta v} = 2v$$

Versión del algoritmo:

$$\theta(1) = \textit{arbitrario}$$

$$\theta(k+1) = \theta(k) + p_k \sum_{n=1}^N (y_n - \theta(k)^t x_n) x_n - \theta(k)$$

Versión del algoritmo muestra a muestra:

$$\theta(1) = \textit{arbitrario}$$

$$\theta(k+1) = \theta(k) + p_k (y(k) - \theta(k)^t x(k)) x(k) - \theta(k)$$