

Redes Neuronales Multicapa

Marcos Esteve Casademunt

Enero 2019

1. Ejercicio 1

Uno de los problemas que presenta el algoritmo BackProp es que converge lentamente. Una posible solución pasa por añadir una inercia o momentum con un peso $0 \leq v < 1$.

La implementación resulta muy similar a la del algoritmo original. Tendremos que añadir un parametro de entrada v y modificar $\Delta\theta$ añadiendo el nuevo parámetro.

1.1. Batch

Entrada: Topología, pesos iniciales $\theta_{ij}^l, 1 \leq l \leq L, 1 \leq i \leq M_l, 0 \leq j \leq M_{l-1}$, factor de aprendizaje p , condiciones de convergencia, N datos de entrenamiento S , **momentum** $0 \leq v < 1$.

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S

Mientras no se cumplan las condiciones de convergencia:

Para $1 \leq l \leq L, 1 \leq i \leq M_l, 0 \leq j \leq M_{l-1}$, inicializar $\Delta\theta_{ij}^l = 0$

Para cada muestra de entrenamiento $(x, t) \in S$

Desde la capa de entrada a la de salida ($l=1, \dots, L$)

Para $1 \leq i \leq M_l$ calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l=L, \dots, 1$)

Para cada nodo ($1 \leq i \leq M_l$),

Calcular $\delta_i^l = g'(\phi_i^l)(t_{ni-s_i^L})$ si $l=L$ o $g'(\phi_i^l)(\sum_r \delta_r^{l+1} \theta_{ri}^{l+1})$

Para cada peso θ_{ij}^l ($0 \leq j \leq M_{l-1}$) calcular: $\Delta\theta_{ij}^l = v\Delta\theta_{ij}^l + p\delta_i^l s_j^{l-1}$

Para $1 \leq l \leq L, 1 \leq i \leq M_l, 0 \leq j \leq M_{l-1}$ Actualizar pesos: $\theta_{ij}^l = \theta_{ij}^l + \frac{1}{N}\Delta\theta_{ij}^l$

1.2. Incremental

Entrada: Topología, pesos iniciales $\theta_{ij}^l, 1 \leq l \leq L, 1 \leq i \leq M_l, 0 \leq j \leq M_{l-1}$, factor de aprendizaje p , condiciones de convergencia, N datos de entrenamiento S , **momentum** $0 \leq v < 1$.

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S

Mientras no se cumplan las condiciones de convergencia:

Para cada muestra de entrenamiento $(x, t) \in S$

Desde la capa de entrada a la de salida ($l=1, \dots, L$)

Para $1 \leq i \leq M_l$ calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l = L, \dots, 1$)

Para cada nodo ($1 \leq i \leq M_l$)

Calcular $\delta_i^l = g'(\phi_i^l)(t_{ni-s_i^L})$ si $l == L$ o $g'(\phi_i^l)(\sum_r \delta_r^{l+1} \theta_{ri}^{l+1})$

Para cada peso θ_{ij}^l ($0 \leq j \leq M_{l-1}$) actualizar: $\Theta_{ij}^l = \mathbf{v} \Theta_{ij}^l + \frac{p}{N} \delta_i^l s_j^{l-1}$

2. Ejercicio 2

Con el fin de evitar que los pesos sean muy grandes y por tanto provoquen una parálisis de la red se pretende implantar un factor de amortiguamiento en el algoritmo BackProp

La implementación resulta muy similar a la del algoritmo original. Tendremos que añadir un parámetro de entrada λ y modificar $\Delta\Theta$ añadiendo el nuevo parámetro.

2.1. Batch

Entrada: Topología, pesos iniciales θ_{ij}^l , $1 \leq l \leq L, 1 \leq i \leq M_l, 0 \leq j \leq M_{l-1}$, factor de aprendizaje p , condiciones de convergencia, N datos de entrenamiento S . **Factor de regularización** λ .

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S

Mientras no se cumplan las condiciones de convergencia:

Para $1 \leq l \leq L, 1 \leq i \leq M_l, 0 \leq j \leq M_{l-1}$, inicializar $\Delta\theta_{ij}^l = 0$

Para cada muestra de entrenamiento $(x, t) \in S$

Desde la capa de entrada a la de salida ($l=1, \dots, L$)

Para $1 \leq i \leq M_l$ calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l = L, \dots, 1$)

Para cada nodo ($1 \leq i \leq M_l$)

Calcular $\delta_i^l = g'(\phi_i^l)(t_{ni-s_i^L})$ si $l == L$ o $g'(\phi_i^l)(\sum_r \delta_r^{l+1} \theta_{ri}^{l+1})$

Para cada peso θ_{ij}^l ($0 \leq j \leq M_{l-1}$) calcular: $\Delta\theta_{ij}^l = p\delta_i^l s_j^{l-1} - 2\lambda\theta_{ij}^l$

Para $1 \leq l \leq L, 1 \leq i \leq M_l, 0 \leq j \leq M_{l-1}$ Actualizar pesos: $\theta_{ij}^l = \theta_{ij}^l + \frac{1}{N} \Delta\theta_{ij}^l$

2.1.1. Incremental

Entrada: Topología, pesos iniciales $\theta_{ij}^l, 1 \leq l \leq L, 1 \leq i \leq M_l, 0 \leq j \leq M_{l-1}$, factor de aprendizaje p , condiciones de convergencia, N datos de entrenamiento S , **Factor de regularización** λ .

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S

Mientras no se cumplan las condiciones de convergencia:

Para cada muestra de entrenamiento $(x, t) \in S$

Desde la capa de entrada a la de salida ($l=1, \dots, L$)

Para $1 \leq i \leq M_l$ calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l = L, \dots, 1$)

Para cada nodo ($1 \leq i \leq M_l$),

Calcular $\delta_i^l = g'(\phi_i^l)(t_{ni} - s_i^l)$ si $l = L$ o $g'(\phi_i^l)(\sum_r \delta_r^{l+1} \theta_{ri}^{l+1})$

Para cada peso θ_{ij}^l ($0 \leq j \leq M_{l-1}$) actualizar : $\Theta_{ij}^l = -2 p \lambda \Theta_{ij}^l + \frac{p}{N} \delta_i^l s_j^{l-1}$